Manejo y Visualización de Datos
1er semestre 2026

<u>Profesor</u>: Francisco Valentini (ftvalentini@gmail.com)
<u>Asistente</u>: Juan Octavio Castro (jocastro@udesa.edu.ar)

Objetivos de aprendizaje

El objetivo general de este curso es familiarizar a los estudiantes con el manejo y la visualización de datos sociales. Se espera que durante el curso los estudiantes:

- logren dominar las herramientas técnicas necesarias para todas las etapas del análisis de datos: recolección, almacenamiento, limpieza, manipulación, análisis y visualización.
- construyan un criterio propio y una mirada crítica sobre el uso de estas herramientas y la interpretación de resultados.
- aprendan a analizar datos con el lenguaje de programación R, enfocándose en principios que permitan transferir el conocimiento a otros lenguajes populares, como Python.
- aprendan a comunicar ideas basadas en evidencia empírica de manera efectiva.

Contenidos

La primera parte del curso se enfoca en la gestión y manejo de datos, abarcando desde la adquisición y almacenamiento hasta el procesamiento y manipulación. La segunda parte profundiza en la visualización y comunicación, explorando los fundamentos del diseño visual, tipos de gráficos y principios para transmitir ideas de forma efectiva.

Aunque el enfoque principal del curso está en los datos tabulares, también vamos a estudiar técnicas específicas para manipular y analizar otros tipos de datos, como jerárquicos, geoespaciales y textuales.

Todos los contenidos se van a complementar con aplicaciones prácticas usando el lenguaje R.

Modalidad de trabajo

El curso se estructura en dos encuentros semanales. En las clases magistrales (martes) presentaremos los fundamentos teóricos y las herramientas para el manejo y visualización de datos; dado el enfoque práctico del curso, se incluirán demostraciones introductorias en R. Las clases tutoriales (viernes) se destinarán a

la aplicación de estas herramientas en casos reales y datos de interés para las ciencias sociales.
El programa que se presenta más abajo detalla los contenidos y las lecturas que corresponden a cada unidad. La asignación específica de lecturas para cada clase se va a indicar durante la cursada.
Las consultas podrán realizarse presencialmente o vía e-mail.

Mecanismo de evaluación
El curso se estructura en torno a tres instancias de evaluación:

- Proyecto grupal (2 entregas): consiste en el desarrollo colectivo de un análisis de datos completo, desde la obtención hasta la interpretación de los resultados.
    - Primera entrega: envío por e-mail de un repositorio de código y un informe que incluya las preguntas de investigación, la descripción del procesamiento de los datos y un análisis exploratorio breve.
    - Segunda entrega: presentación oral y presencial de los resultados finales. Se califica con una nota de 0 a 10.
- Trabajos prácticos (individuales): ejercicios orientados a evaluar la comprensión y aplicación de herramientas. La calificación de cada uno es Aprobado o Desaprobado.
- Examen final: evaluación escrita, individual y presencial sobre todos los contenidos de la materia. Se califica con una nota de 0 a 10.

Las consignas detalladas se entregarán durante la cursada.

La nota final se define con la siguiente ponderación:

- 50% segunda entrega del proyecto grupal.
- 50% examen final.

Para aprobar la materia es necesario cumplir con todas las siguientes condiciones:

- Aprobar la totalidad de los trabajos prácticos.
- Obtener una nota final ponderada de al menos 4 puntos.
- Contar con un mínimo de 75% de asistencia.

Se reservan fechas de recuperatorios para exámenes y reentregas de trabajos prácticos desaprobados.

Plagio y deshonestidad intelectual

La Universidad de San Andrés exige un estricto apego a los cánones de honestidad intelectual. La existencia de plagio constituye un grave deshonor, impropio de la vida universitaria. Su configuración no sólo se produce con la existencia de copia literal en los exámenes presenciales, sino toda vez que se advierta un aprovechamiento abusivo del esfuerzo intelectual ajeno. El Código de Ética (http://www.udesa.edu.ar/files/Institucional/Politicas_y_Procedimientos_Universidad_de_San_Andres.pdf) considera conducta punible la apropiación de la labor intelectual ajena, por lo que se recomienda apegarse a los formatos académicos generalmente aceptados (MLA, APA, Chicago, etc.) para las citas y referencias bibliografías (incluyendo los formatos *on-line*). En caso de duda recomendamos consultar el sitio: http://www.udesa.edu.ar/Unidades-Academicas/departamentos-y-escuelas/Humanidades/Prevencion-del-plagio/Que-es-el-plagio. La violación de estas normas dará lugar a sanciones académicas y disciplinarias que van desde el apercibimiento hasta la expulsión de la Universidad.

PROGRAMA

1. **Fundamentos del manejo y visualización de datos**. Datos e información. Recolección, limpieza y documentación de datos. Replicabilidad y reproducibilidad. Repositorios y control de versiones. Scripts y notebooks. Fundamentos de R y RStudio.

   Bibliografía obligatoria:
   Alexander 2023 (cap. 1-3), Llaudet & Imai 2023 (cap. 1), Weidmann 2023 (cap. 1)
   Bibliografía complementaria:
   Baumer et al. 2024 (cap. 1 & 8, ap. D), Foster et al. 2021 (cap. 12), Squire 2015 (cap. 1), Zozus 2017 (cap. 1-3)

2. **Data wrangling en datos tabulares**. Data frames. Operaciones sobre filas y columnas. Split-apply-combine. Reshaping: formatos "wide" y "long". El concepto de "tidy data". Joins y fuzzy matching. Tipos de datos: booleanos, numéricos, strings, categóricos, fechas. Valores faltantes.

   Bibliografía obligatoria:
   Magallanes Reyes 2022 (cap. 2), Weidmann 2023 (cap. 3), Wickham et al. 2023 (ch. 3-5 & 18-19)
   Bibliografía complementaria:
   Baumer et al. 2024 (cap. 4-6), Urdinez & Cruz 2020 (cap. 2 & 11), Weidmann 2023 (cap. 6 & 7), Wickham et al. 2023 (cap. 12-17)

3. **Gestión de datos**. Archivos binarios y de texto. CSV (Comma-Separated Values). Compresión de archivos. Formatos binarios de R. Bases de datos relacionales y SQL (Structured Query Language). Parquet. Datos jerárquicos y JSON (JavaScript Object Notation).

   Bibliografía obligatoria:
   Weidmann 2023 (cap. 4, 8-10 & 14), Wickham et al. 2023 (cap. 20-23)

Bibliografía complementaria:
Baumer et al. 2024 (cap. 15, 16 & 21), Foster et al. 2021 (cap. 4), Urdinez & Cruz 2020 (cap. 4)

4. **APIs (Application Programming Interfaces) y web scraping**. Motivación. URLs (uniform resource locator), HTML (Hypertext Markup Language) y XML (Extensible Markup Language). Selectores CSS (Cascading Style Sheets). Scraping estático y dinámico. APIs: solicitudes, autenticación y códigos de estado. Ética y aspectos legales.

   Bibliografía obligatoria:
   Foster et al. 2021 (cap. 2), Wickham et al. 2023 (cap. 24)
   Bibliografía complementaria:
   Urdinez & Cruz 2020 (cap. 12), Alexander 2023 (cap. 7)

5. **Procesamiento de lenguaje natural**. Corpora, documentos y vocabulario. Unicode. n-gramas. Tokenización, stemming y lematización. Stop words. Expresiones regulares. Matriz documento-término. Log odds ratio, bag of words, tf-idf (term frequency - inverse document frequency). Métodos para clasificar y medir similitud entre documentos.

   Bibliografía obligatoria:
   Weidmann 2023 (cap. 12), Jurafsky & Martin 2026 (cap. 2), Card et al. 2022
   Bibliografía complementaria:
   Baumer et al. 2024 (cap. 19), Foster et al. 2021 (cap. 8), Imai 2017 (cap. 5.1), Urdinez & Cruz 2020 (cap. 13), Magallanes Reyes 2022 (cap. 8)

6. **Visualización y análisis exploratorio de datos**. La gramática de los gráficos: estética, escalas, guías, facetas, capas. Sistemas de coordenadas y ejes. Escalas de color. Insights a partir de una variable, dos variables y tres o más variables. Visualización de cantidades, distribuciones, proporciones, relaciones, y datos apareados. Principios del diseño de gráficos y errores comunes. Formatos de archivo de imagen.

   Bibliografía obligatoria:
   Magallanes Reyes 2022 (cap. 3-6), Urdinez y Cruz 2020 (cap. 3)
   Bibliografía complementaria:
   Baumer et al. 2024 (cap. 2-3), Imai 2018 (cap. 3.3 & 3.6), Llaudet & Imai 2023 (cap. 3), Wilke 2019 (cap. 17-26)

7. **Visualización de modelos estadísticos e incertidumbre**. Visualización de la incertidumbre en estimaciones puntuales y en ajustes de curvas. Diagnóstico y análisis exploratorio para modelos de regresión. Gráficos y tablas para presentar resultados de regresión lineal y logística.

Bibliografía obligatoria:
Urdinez y Cruz 2020 (cap. 5-6 & 8), Wilke 2019 (cap. 16)
Bibliografía complementaria:
Llaudet & Imai 2023 (cap. 4-5, 7), Imai 2018 (cap. 4.2-4.3 & 7.1-7.2), Urdinez y Cruz 2020 (cap. 11.4), Baumer et al. 2024 (cap. 9-10 & ap. E)

8. **Datos geoespaciales**. Proyecciones bidimensionales de datos espaciales. Sistemas de referencia de coordenadas. Puntos, líneas y polígonos. Formatos de archivo para datos espaciales. Mapeo de variables en capas. Mapas de coropletas y cartogramas. Operaciones sobre datos geoespaciales. Visualización de datos espacio-temporales.

   Bibliografía obligatoria:
   Urdinez y Cruz 2020 (cap. 16), Weidmann 2023 (cap. 11), Wilke 2019 (cap. 15)
   Bibliografía complementaria:
   Baumer et al. 2021 (cap. 17-18), Magallanes Reyes 2022 (cap. 7), Imai 2018 (cap. 5.3)

9. **Comunicación y presentación de resultados**. Notebooks para desarrollo, comunicación y colaboración. Widgets y gráficos dinámicos, interactivos, y personalizados. Dashboards. Animaciones. Consejos para una presentación y comunicación efectiva.

   Bibliografía obligatoria:
   Baumer et al. 2024 (cap. 14), Wickham et al. 2023 (cap. 28-29)
   Bibliografía complementaria:
   Foster et al. 2021 (cap. 6), Alexander 2023 (cap. 4)

Referencias

Alexander, R. (2023). *Telling stories with data: With applications in R and Python*. CRC Press.

Baumer, B. S., Kaplan, D. T., & Horton, N. J. (2024). *Modern data science with R* (3rd ed.). CRC Press.

Card, D., Serina, S., Khandelwal, A., Poole, K. J., Robinson, D., & Smith, N. A. (2022). *Computational analysis of 140 years of US political speeches reveals more positive but increasingly polarized framing of immigration*. Proceedings of the National Academy of Sciences (PNAS), 119(31), e2120515119.

Foster, I., Ghani, R., Jarmin, R. S., Kreuter, F., & Lane, J. (Eds.). (2021). *Big data and social science: Data science methods and tools for research and practice* (2nd ed.). CRC Press.

Imai, K. (2018). *Quantitative social science: An introduction*. Princeton University Press.

Jurafsky, D., & Martin, J. H. (2026). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models* (3rd ed.). Online manuscript released January 6, 2026.

Llaudet, E., & Imai, K. (2023). *Data analysis for social science: A friendly and practical introduction*. Princeton University Press.

Magallanes Reyes, J. M. (2022). *Data visualization for social and policy research: A step-by-step approach using R and Python*. Cambridge University Press.

Squire, M. (2015). *Clean data*. Packt Publishing.

Urdinez, F., & Cruz, A. (2020). *R for political data science: A practical guide*. CRC Press.

Weidmann, N. B. (2023). *Data management for social scientists: From files to databases*. Cambridge University Press.

Wickham, H., Çetinkaya-Rundel, M., & Grolemund, G. (2023). *R for data science: Import, tidy, transform, visualize, and model data* (2nd ed.). O'Reilly Media.

Wilke, C. O. (2019). *Fundamentals of data visualization: A primer on making informative and compelling figures*. O'Reilly Media.

Zozus, M. N. (2017). *The data book: Collection and management of research data*. CRC Press.